

激光与光电子学进展

无监督网络驱动散射成像方法研究进展(特邀)

乔龙宇¹, 林冰¹, 樊学强¹, 孙希勋^{1,2}, 彭志勇², 郭忠义^{1*}¹合肥工业大学计算机与信息学院, 安徽 合肥 230601;²天津津航技术物理研究所, 天津 300192

摘要 基于深度学习的透过散射介质成像技术是光学计算成像领域的关键研究方向,近年来受到广泛关注。尽管有监督学习方案在该领域已取得一定进展,但在实际应用和关键技术方面仍面临诸多挑战。例如,有监督学习高度依赖精确配对的训练数据,但在复杂散射环境中获取大量精准标注的数据极为困难且不切实际。此外,由于数据样本的表征能力有限,基于监督学习的成像方案在应对非训练场景时往往表现出较差的泛化性能。为解决上述问题,基于无监督训练策略的散射介质成像方法逐渐成为研究热点,并取得了显著的研究成果。因此,本文从神经网络模型的角度出发,对基于无监督学习策略的散射介质成像方法中的各类网络框架进行分类,将现有的无监督学习驱动散射成像技术归纳为四类并加以阐述和总结,分别是基于自编码器的无监督散射成像技术、基于生成对抗网络的无监督散射成像技术、基于扩散模型的无监督散射成像技术以及基于卷积神经网络的无监督散射成像技术。针对这些成像方法,详细分析了其性能优势及存在的不足,并对基于神经网络模型的无监督散射介质成像技术的未来发展方向进行了展望。本文旨在帮助研究人员了解各类无监督散射介质成像技术的原理与最新进展,明确不同技术的特点及其适用场景,从而推动散射介质成像技术的工程化应用进程。

关键词 散射介质成像; 深度学习; 无监督学习

中图分类号 TP3

文献标志码 A

DOI: 10.3788/LOP250975

Research Advances on Unsupervised Networks-Driven Imaging Through Scattering Media (Invited)

Qiao Longyu¹, Lin Bing¹, Fan Xueqiang¹, Sun Xixun^{1,2}, Peng Zhiyong², Guo Zhongyi^{1*}¹School of Computer and Information, Hefei University of Technology, Hefei 230601, Anhui, China;²Tianjin Jinhang Institute of Technical Physics, Tianjin 300192, China

Abstract Deep learning-based imaging through scattering media has emerged as a crucial research direction in computational optical imaging, garnering significant attention in recent years. While supervised learning approaches have made notable progress in this field, they still face numerous challenges in practical applications and key technologies. For instance, supervised learning heavily relies on precisely paired training data, which is extremely difficult and impractical to obtain in complex scattering environments. Moreover, supervised imaging methods often demonstrate poor generalization performance when confronting scenarios outside their training scope, due to the limited representational capacity of data samples. To address these challenges, unsupervised training strategies for imaging through scattering media have gradually become a research focus, yielding remarkable results. This paper classifies various network frameworks in unsupervised learning-based scattering media imaging from a neural network perspective. We categorize existing unsupervised learning-driven scattering imaging techniques into four types: autoencoder-based, generative adversarial network-based, diffusion model-based, and convolutional neural network-based unsupervised scattering imaging technologies. For each method, we provide detailed analysis of their performance advantages and limitations. Finally, we present future development prospects for neural network-based unsupervised imaging through scattering media. This review aims to help researchers understand the principles and latest developments in various unsupervised scattering media imaging techniques, clarify the characteristics and applicable scenarios of different technologies, thereby advancing the engineering application process of scattering media imaging technology.

Key words imaging through scattering media; deep learning; unsupervised learning

收稿日期: 2025-04-09; 修回日期: 2025-05-06; 录用日期: 2025-05-13; 网络首发日期: 2025-05-19

基金项目: 国家自然科学基金(61775050)

通信作者: *guozhongyi@hfut.edu.cn

1 引言

透过散射介质成像在深海探测^[1-2]、大气遥感^[3-4]、医学检测^[5-7]等领域具有重要的应用价值,为国防安全与民生保障提供了可靠的技术支持^[8-12]。然而,散射介质的普遍存在导致多场景下的成像质量下降、目标信息受损以及空间分辨率降低等问题,从而限制了后续任务的精度。常见的散射环境如图 1 所示。为了提高成像质量,研究人员通过研究散射现象总结了物理模型,并提出了一系列成像方法来抑制或消除散射的影响,以突出目标信息并提高成像质量,例如,记忆效应^[13-14]、传输矩阵^[15-16]、波前整形^[17-18]和关联成像^[19-20]等。此外,部分研究者还从偏振角度出发,探索了多维偏振信息在不同散射环境中的表征能力^[21-23]。然而,传统成像方法在复杂散射环境中的局限性仍然显著,难以满足日益增长的成像需求。近年来,随着计算机技术的快速发展,深度学习技术的出现显著突破

了传统成像方法的局限性,展现出更高质量的成像效果和更强的泛化能力^[24-30]。目前,基于深度学习的散射介质成像(IDL)研究普遍采用需要配对数据训练网络模型的监督学习策略^[31-36]。尽管标签数据提供的有效约束能够显著提升成像效果,但其也带来了一定的限制。首先,受实际测量条件和设备精度的限制,在水下等散射环境中获取大量且准确的标签数据集极为困难。尽管某些场景下已有公开数据集,但当训练后的模型迁移到真实应用场景时,仍存在泛化性能不足的问题。其次,受限于训练数据的表达能力,模型在非训练环境中的泛化性仍具有一定局限性。虽然扩大数据规模可能增强模型的表达能力,但仍需考虑模型容量增加所导致的资源损耗以及数据冗余引发的过拟合问题。为解决上述问题,并考虑到成像模型框架正朝着轻量化方向发展的趋势,基于无监督深度学习的散射介质成像(IUL)方法逐渐成为研究热点^[37-39]。

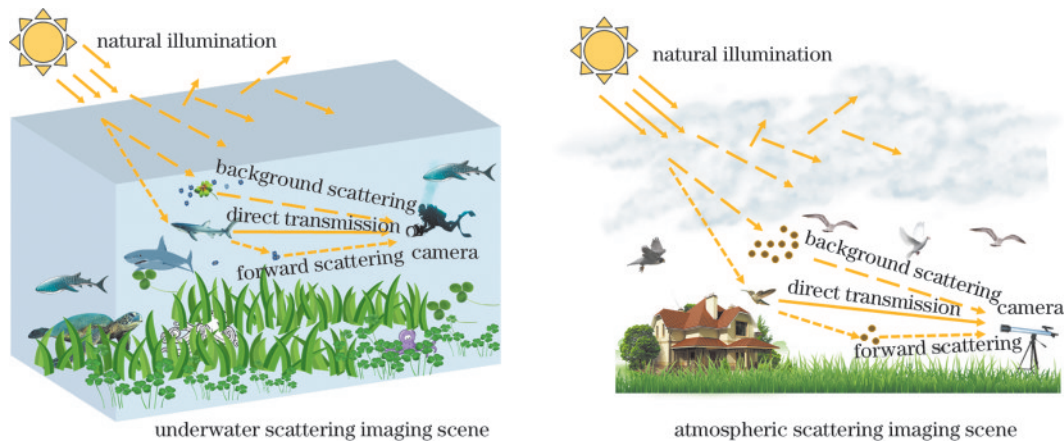


图 1 水下散射环境和大气散射环境

Fig. 1 Underwater scattering environment and atmospheric scattering environment

无监督学习作为一种无需标签约束且可实现自主特征提取的模型训练方法,能够直接从原始数据中挖掘潜在的特征结构和模式,从而优化模型^[40-45]。与监督学习相比,它无需精确的标签数据作为约束,这显著降低了在复杂散射环境下获取成对数据的难度。此外,无监督学习方法提取的特征能够探索更广泛且无偏的知识,使模型具备更强的泛化能力。然而,由于缺乏标签数据作为约束条件,如何有效引导学习过程,推动模型向高质量成像结果的方向发展,是IUL面临的重要挑战。因此,本文基于生成模型和卷积神经网络模型这两种网络框架对IUL进行了分析和总结。其中,生成模型包括自编码器(AE)、生成对抗网络(GAN)以及新兴的扩散模型^[46-50]。基于AE的IUL以变分自编码器(VAE)为例,其结合编码器和解码器结构以及变分推理的概念,首先利用编码器将输入数据映射到潜在空间,并假设隐变量服从某种先验分布,再通过解码器重构数据以生成新样本。基于GAN的IUL则是通过生

成器与判别器的对抗学习实现共同进化,最终使生成器生成的样本逼近真实数据。与传统生成模型不同,基于扩散模型的IUL通过双向扩散过程,从随机高斯噪声中逐步去噪以生成高质量的数据样本。而基于卷积神经网络模型的IUL侧重于在使用卷积神经网络(CNN)进行特征提取的基础上,通过设计针对性的模块、损失函数或评价指标实现无监督成像过程。基于以上两种方案,本文重点介绍了各种IUL的框架,并从不同角度对比分析了它们各自的优势与不足。最后,本文展望了IUL技术可能的未来研究方向。

2 基于生成模型的无监督散射介质成像

无监督学习的核心在于从未标注的数据中自动挖掘潜在的数据特征和内在结构。在图像领域,通常通过生成模型对图像域数据的先验分布进行分析和建模,训练后的生成模型能够为不同成像条件下的图像

重建提供有效的正则化约束。常见的用于散射介质成像的生成模型包括:AE、GAN 和扩散模型。因此,本节主要介绍基于生成模型实现的IUL方法。

2.1 基于自编码器的无监督散射介质成像

AE作为一种经典的无监督深度学习架构,在散射介质成像中展现出强大的特征提取与重建能力。自编码器本质上由编码器和解码器构成的双模块神经网络组成,其核心目标是通过编码器将输入数据映射至低维潜在空间以提取关键特征,再通过解码器从潜在空间中重构原始输入,通过最小化输入与输出的重建

误差实现无监督学习。Sonawane等^[51]针对水下场景中光照衰减和悬浮颗粒散射导致的图像退化问题,提出了一种基于卷积AE的水下图像和视频增强框架,如图2(a1)所示。该方法通过卷积AE分别对水下图像和增强图像进行独立的特征提取,然后通过引入映射网络建立退化特征与增强特征间的映射关系。在卷积自编码器中,图像 X 被输入网络后会先后经历编码过程,其具体过程可描述如下:

$$Y_i = \text{encoder}(X) = \sigma(X * W^i + b) \quad (1)$$

$$G = \text{decoder}(Y_i) = \sigma(Y_i * \tilde{W}^i + \tilde{b}) \quad (2)$$

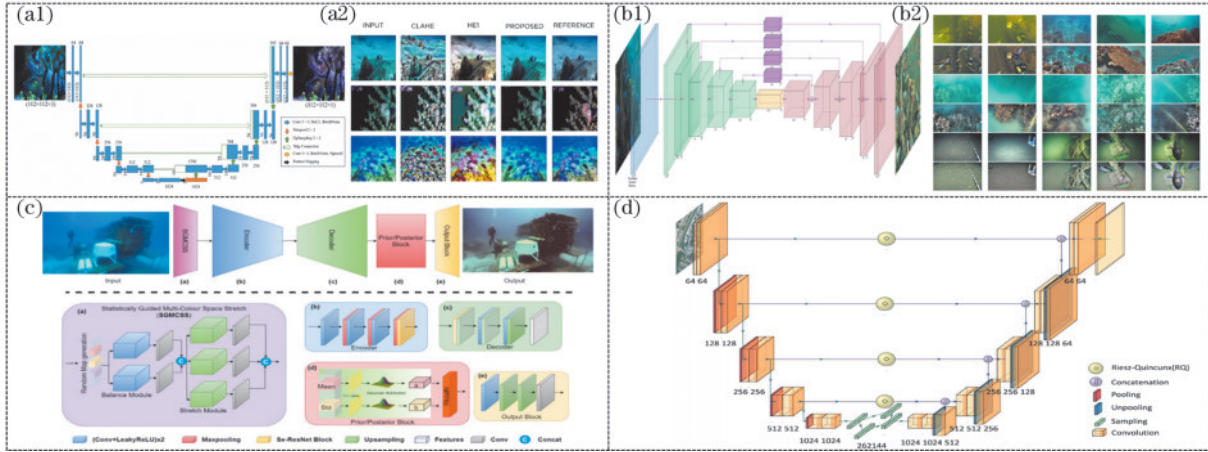


图2 基于AE的IUL方法的具体算法。(a1)(a2)基于卷积AE的水下图像和视频增强框架的网络架构及其与不同方法的对比结果^[51]; (b1)(b2)基于分数积分的Retinex算法增强框架的网络架构及其与不同方法的对比结果^[52]; (c) UDNet增强框架的网络架构^[53]; (d) RQUNet-VAE的网络架构^[54]

Fig. 2 Algorithms for AE-based IUL methods. (a1)(a2) Network structure of underwater image and video enhancement framework based on convolutional AE and its comparative results with different methods^[51]; (b1)(b2) network structure of Retinex algorithm enhanced framework based on fractional integration and comparison results with different methods^[52]; (c) network structure of UDNet enhancement framework^[53]; (d) network structure of the RQUNet-VAE method^[54]

输入图像 X 经过二维卷积核 W_i 的卷积操作与偏置项 b 的叠加,再通过非线性激活函数 $\sigma(\cdot)$ 映射,得到低维特征表示 Y_i 。低维特征 Y_i 通过卷积核 \tilde{W}_i 与偏置 \tilde{b} 进行同样的卷积操作,并经过激活函数 $\sigma(\cdot)$ 重建生成图像 G 。其中, $*$ 表示卷积运算操作。实验表明,该方法不仅提升了水下图像的主观视觉效果,其增强结果的对比如图2(a2)所示,还在峰值信噪比(PSNR)和结构相似度(SSIM)等客观评价指标上取得了显著提升,其对应数值如表1所示。然而,需要说明的是,该方法的分阶段特征提取策略需要独立训练各个子网络,这显著增加了算法处理的复杂度。为优化特征提取效率,Yu等^[52]将基于分数积分的Retinex算法与无监督AE网络相结合,提出了一种端到端的水下图像增强框架,其网络架构如图2(b1)所示。该框架首先将一种改进的分数积分滤波器与多尺度Retinex算法结合以初步增强水下图像,该滤波器能够有效估计光照分量并保持边缘细节,同时避免传统高斯滤波器导致的过度平滑问题。随后通过集成注意力模块的U-Net自编码器网络对初步增强的图像进行细化重建,并联合

四种损失函数进行多目标优化,以确保最终图像增强的多样性和稳定性。作者从三个公开数据集中挑选了一些代表性图像进行视觉效果对比,其结果展示如图2(b2)所示。该方法的定量分析结果如表1所示,其PSNR和SSIM指标分别达到27.802和0.849,领先于所对比的其他方法。此外,在亮度增强率(LER)和对比度增强率(CER)指标上也分别达到了1.583和1.955。进一步地,Saleh等^[53]提出了一种名为Uncertainty Distribution Network(UDNet)的无监督深度学习框架,其网络架构如图2(c)所示,用于鲁棒的水下图像增强。该框架借助概率不确定性建模和编码器-解码器架构解决水下图像存在的随机失真和低对比度等问题,其底层的概率框架可表示为

$$p(y|x) \approx p(y|z_{\max}, x), \quad z_{\max} \sim p(z|x) \quad (3)$$

式中: x 表示低质量的输入图像; y 表示增强后的干净图像;隐变量 z 用于表示图像增强过程中的不确定性; $p(z|x)$ 表示在给定观测样本 x 条件下隐变量 z 的条件分布; z_{\max} 为概率最大的隐变量采样; $p(y|z_{\max}, x)$ 表示在给定 z_{\max} 和输入图像 x 的条件下获取干净图像 y 的概

率分布。式(3)表明,模型并非直接学习输入图像 \mathbf{x} 到目标图像 \mathbf{y} 的确定性映射,而是通过学习上述概率分布生成具有不确定性的增强图像。实验结果表明,UDNet在8个公开数据集上均取得了与现有监督和无监督方法相当甚至更优的性能,其在EUVP数据集上的定量结果如表1所示。除了采用有参考图像评价指标PSNR和SSIM外,该网络在水下图像质量测量(UIQM)和水下彩色图像质量评估(UCIQE)这两个无参考图像评价指标上也取得了最佳的结果。除水下成像外,AE在卫星遥感等场景的散射介质成像中也展现出潜力。Thai等^[54]针对卫星图像中由大气散射和传感器噪声引起的退化问题,提出了一种创新的Riesz-Quincunx-UNet变分自编码器(RQUNet-VAE)架构,其网络架构如图2(d)所示。RQUNet-VAE的核心在于其独特的Riesz-Quincunx小波变换,该变换能够有效捕捉图像的多尺度特征和方向信息,同时避免传统卷积神经网络中池化操作导致的信息丢失问题。其中,RQUNet-VAE在PSNR和SSIM指标上远优于所对比的其他方法,其定量数值表征如表1所示。

表1 基于不同AE的IUL方法性能分析

Table 1 Performance analysis of IUL methods based on different AEs

Ref.	PSNR ↑	SSIM ↑	LER ↑	CER ↑	UIQM ↑	UCIQE ↑
[51]	18.770	0.633	-	-	-	-
[52]	27.802	0.849	1.583	1.955	-	-
[53]	22.960	0.771	-	-	3.265	0.749
[54]	39.087	0.971	-	-	-	-

综上所述,基于自编码器的无监督散射介质成像方法通过特征压缩与重建机制,在缺乏配对数据的情况下能够实现对退化图像的有效恢复。然而,现有方法仍面临潜在空间表征能力有限、多模态退化适应不足等问题,未来研究需进一步探索优化策略以提升模型的泛化性与实用性。

2.2 基于GAN的无监督散射介质成像

在图像处理领域,GAN^[55]已成为最成功的生成模型之一。它不仅能够精准地估计数据分布,还能生成大量全新的样本数据,从而极大地拓展图像数据的多样性,为数据增强^[56]、图像增强^[57-59]、图像恢复^[60-61]等任务提供了有力支持。GAN的训练过程是一个迭代优化过程,其中生成器和判别器交替训练,直至网络达到平衡状态。为了实现这一目标,GAN的损失函数通常采用下式中的交叉熵损失来表示,通过优化生成器和判别器的对抗目标,逐步提升生成图像的质量,并使判别器能够准确区分真实数据与生成数据。

$$\min_G \max_D V(D, G) = E_{\mathbf{x} \sim P_{\text{data}}(\mathbf{x})} \left\{ \log [D(\mathbf{x})] \right\} + E_{\mathbf{z} \sim P_z(\mathbf{z})} \left\{ \log \{1 - D[G(\mathbf{z})]\} \right\} \quad (4)$$

式中: \mathbf{x} 表示真实数据; $P_{\text{data}}(\mathbf{x})$ 表示真实数据集; \mathbf{z} 表示随机噪声; $P_z(\mathbf{z})$ 表示随机噪声的分布; G 表示生成器, $G(\mathbf{z})$ 表示生成器生成的数据; D 表示判别器, $D(\mathbf{x})$ 表示判别器对真实数据进行判别; $D[G(\mathbf{z})]$ 表示判别器对生成数据进行判别。GAN的训练可以视为一个基于值函数 $V(D, G)$ 的博弈过程。在此过程中,生成器 G 和判别器 D 通过相互对抗进行优化。生成器 G 的目标是最小化 $\log \{1 - D[G(\mathbf{z})]\}$,即最大化 $D[G(\mathbf{z})]$ 使得判别器无法正确区分生成数据与真实数据,从而使生成的数据尽可能逼真。判别器 D 的目标则是最大化 $D(\mathbf{x})$ 接近于1,同时最小化 $D[G(\mathbf{z})]$ 接近于0,旨在提升其区分真实数据与生成数据的能力。通过这种博弈机制,生成器与判别器逐步提升性能,最终达到平衡状态。

随着研究的深入,研究人员基于GAN中生成器与判别器之间的对抗训练机制,有效挖掘散射图像数据中的潜在特征,从而实现无监督的图像恢复任务。例如,Yang等^[62]提出了一种基于GAN的方法,用于高效估计去雾模型中的背景光参数,具体网络架构如图3(a1)所示。该方法采用自编码器作为生成器,从输入数据中提取并凝练背景光信息,同时利用判别器优化生成背景光的质量,从而提升模型的整体去雾效果。实验结果如图3(a2)所示,表明该算法不仅能够快速恢复水下模糊图像,而且在非均匀光场条件下仍表现出稳定的性能。作者进一步对该方法进行了定量分析,如表2所示,其熵增强度量(EME)值达到了1.2847,表明该方法在水下目标视觉增强方面具有显著效果。为充分发挥对抗训练的优势,部分研究通过在生成器或判别器中引入高效的网络模块来增强模型的特征分析能力,从而提升散射成像的质量与泛化性能。例如,Yu等^[63]在生成器设计中融入了多种先进的深度学习技术,包括残差层、混合注意力层和并行扩张卷积层,以实现多尺度特征的分析与提取,相应结构如图3(b1)所示。这些模块显著提升了模型聚焦于图像关键区域的能力,增强了对目标信息的分析与表征性能。此外,通过一系列消融实验验证了所引入模块的有效性,具体结果如图3(b2)所示。作者还计算了模型输出的相关评价指标,如表2所示,其中PSNR和SSIM分别达到了26.6451和0.8817,无参考评价指标BRISQUE和NIQE分别达到了21.2218和4.4719。这些结果表明,在生成器设计中引入高效的网络模块对增强成像效果发挥了重要作用。Wang等^[64]提出了一种基于混合注意力引导的生成对抗网络(MAGAN),如图3(c)所示。该网络通过在生成器中引入混合注意力模块层模拟图像中每个像素与图像特征之间的关系,并通过全局判别器和局部判别器共同优化生成图像。该方法能够在增强低照度图像视觉效果的同时去除图像中的噪声影响,并通过与多种传统及基于学习

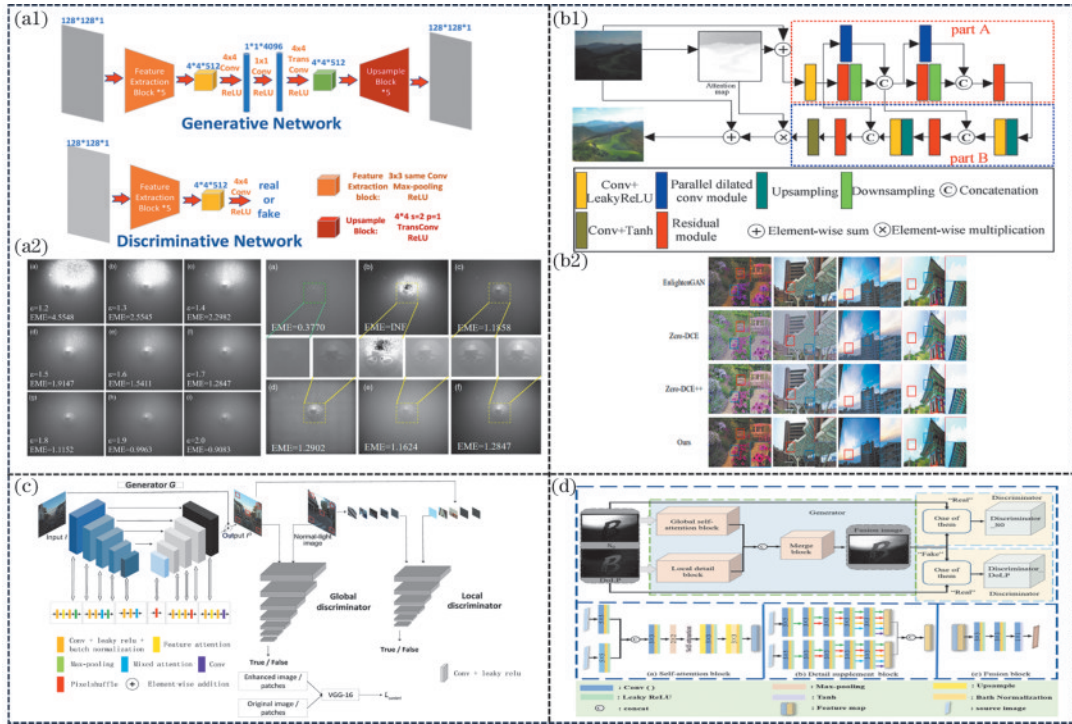


图3 基于GAN的IUL方法的不同算法。(a1)(a2) 水下无监督视觉增强方法的网络结构及其输出的水下视觉增强的结果^[62]；(b1)(b2)低光照视觉增强方法的网络结构及不同方法的对比实验结果^[63]；(c) MAGAN的网络结构^[64]；(d) 基于注意力引导的双鉴别器GAN的方案^[65]

Fig. 3 Different algorithms for GAN-based IUL methods. (a1)(a2) Network structure of unsupervised underwater visual enhancement methods and the results of underwater visual enhancement produced by their outputs^[62]; (b1)(b2) network structure of low-light visual enhancement methods and comparative experimental results of different methods^[63]; (c) network structure of MAGAN^[64]; (d) the method of attention-guided dual-discriminator based GAN^[65]

表2 基于不同GAN的IUL方法性能分析

Table 2 Performance analysis of IUL methods based on different GANs

Ref.	PSNR ↑	SSIM ↑	BRISQUE ↓	NIQE ↓	EME ↑	EN ↓	SD ↑	MI ↑
[62]	—	—	—	—	1.2847	—	—	—
[63]	26.6451	0.8817	21.2218	4.4719	—	—	—	—
[64]	22.3895	0.8470	37.9784	—	—	—	—	—
[65]	71.1607	0.7669	—	—	—	4.1478	52.4640	3.0764

的模型进行定性与定量对比实验,证明了其优越性。表2展示了MAGAN输出结果的PSNR、SSIM和BRISQUE,分别达到22.3895、0.8470和37.9784,表明其在增强低光照图像视觉效果方面的优势。Zhou等^[65]提出了一种基于注意力引导的双鉴别器GAN,如图3(d)所示,用于解决强光环境下弱目标检测问题。该方法通过注意力机制和双鉴别器的引导充分融合光强信息与偏振信息的特征优势,实现了对弱目标的高效视觉增强。为验证其有效性,作者不仅利用实验室数据进行了针对性实验,还利用实际场景数据对不同方法进行了对比测试。结果表明,该方法在弱目标检测任务中取得了更优的性能,其恢复结果的PSNR和SSIM分别达到71.1607和0.7669,相应的熵(EN)、锐度差异(SD)、互信息(MI)分别为4.1478、52.4640、3.0764,展现了其在强光环境下弱目标成像领域的实

际应用潜力^[65]。

尽管基于GAN的方法在图像去噪与增强任务中取得了显著成果,但由于缺乏标签参考数据的约束,这些方法在相对简单的散射环境中表现优异,而在复杂散射环境下的性能仍存在一定缺陷。随着对GAN研究的不断深入,研究者提出了多种改进的GAN以应对不同的任务需求。其中,CycleGAN^[66]作为一种重要的衍生模型,通过引入下式中的循环一致性约束,并采用独特的双生成器-双判别器架构,实现了复杂散射环境中的图像增强。

$$L_{\text{cyc}}(G, F) = E_{\mathbf{x} \sim P_{\text{data}}(\mathbf{x})} \{ \|F[G(\mathbf{x})] - \mathbf{x}\|_1 \} + E_{\mathbf{y} \sim P_{\text{data}}(\mathbf{y})} \{ \|G[F(\mathbf{y})] - \mathbf{y}\|_1 \} \quad (5)$$

式中: $L_{\text{cyc}}(G, F)$ 是衡量生成器将水下图像转换为清晰图像时的损失; \mathbf{x} 和 \mathbf{y} 分别表示原始水下图像和无配对

的清晰图像; G 和 F 分别是两个独立的生成器; $E_{X \sim P_{\text{data}}(x)}[\cdot]$ 表示对水下图像的期望; $E_{X \sim P_{\text{data}}(x)}$ 表示对清晰标签图像的期望。

如图 4 所示, 生成器 G 负责将输入图像 x 从 X 域映射到 Y 域, 并生成对应的图像 $G(x)$, 而生成器 F 则负责将输入图像 y 从 Y 域映射到 X 域, 并生成对应的图像 $F(y)$ 。判别器 D_X 的任务是区分 X 域中的真实图像与

由生成器 F 生成的图像 $F(y)$, 判别器 D_Y 的任务是区分 Y 域中的真实图像与由生成器 G 生成的图像 $G(x)$ 。通过结合对抗训练与循环一致性损失, 生成器和判别器在两个域之间进行迭代优化, 从而使生成图像不仅在视觉上逼真, 同时还能保持两个域之间的映射一致性。这意味着, CycleGAN 即使在一端输入与目标图像完全无关的图片, 另一端仍能有效完成图像恢复任务。




图 4 CycleGAN 的原理图^[66]

Fig. 4 Schematic diagram of CycleGAN^[66]

Yamazaki 等^[67]基于 CycleGAN 提出了一种针对复杂散射环境的目标恢复方法, 具体如图 5(a1) 所示。该方法在不同散射水平、相干与非相干光源下的实验结果均验证了 CycleGAN 在实现复杂散射环境下无监督 IUL 的有效性与泛化性, 如图 5(a2) 所示。平均 SSIM 和均方根误差 (RMSE) 分别达到 0.77 和 0.17

(表 3)。然而, 由于其选用的目标图像相对简单, 未能充分体现其在真实场景中的适用性。因此, 为了有效将 CycleGAN 应用于复杂散射环境下的 IUL, 研究者提出了多种改进策略。Engin 等^[68]通过将循环一致性损失与感知损失相结合, 增强了 CycleGAN 的性能, 如图 5(b1) 所示, 从而提高了纹理信息的恢复质量, 并生

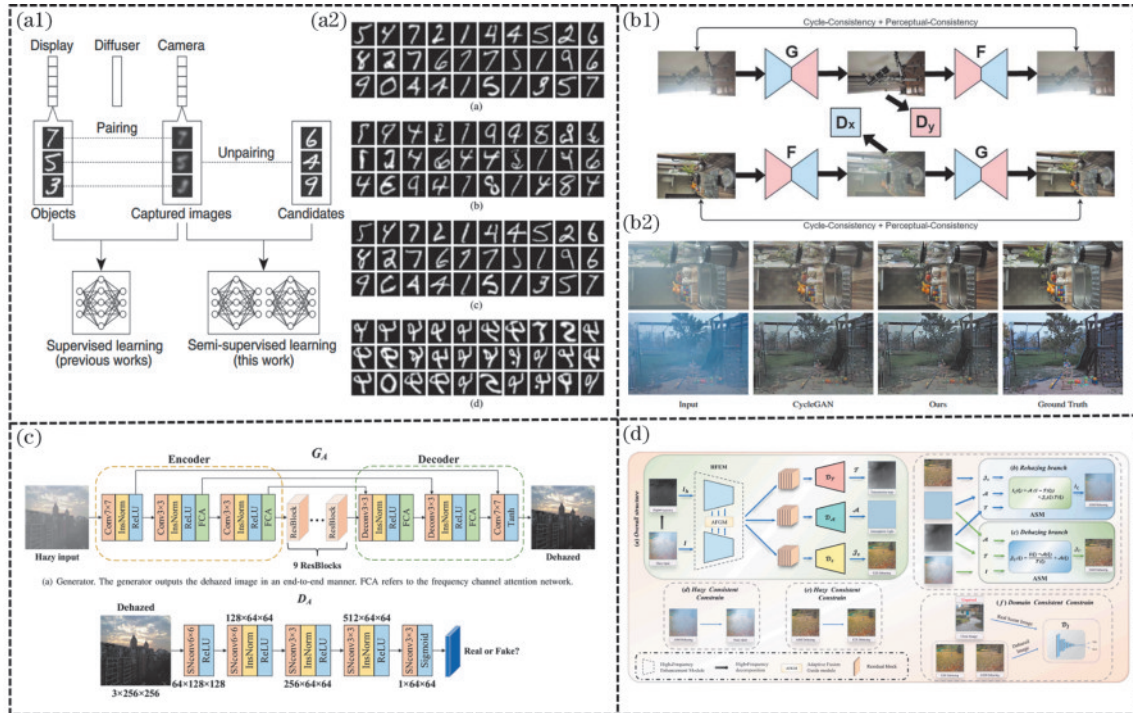


图 5 基于不同 CycleGAN 的 IUL 方法。(a1)(a2) 基于 CycleGAN 的目标恢复方法及模型重建的结果^[67]; (b1)(b2) 循环一致性损失与感知损失相结合的网络结构及其与 CycleGAN 的对比结果^[68]; (c) Cycle-SNSPGAN 方法的网络结构^[69]; (d) UME-Net 方法的网络结构^[70]

Fig.5 IUL methods based on different CycleGAN. (a1)(a2) CycleGAN-based target recovery method and model reconstruction results^[67]; (b1)(b2) network structure combining cyclic consistency loss and perceptual loss and its comparison with CycleGAN^[68]; (c) network structure of Cycle-SNSPGAN method^[69]; (d) network structure of the UME-Net method^[70]

表 3 基于不同 CycleGAN 的 IUL 方法性能分析

Table 3 Performance analysis of IUL methods based on different CycleGANs

Ref.	PSNR \uparrow	SSIM \uparrow	RMSE \downarrow
[67]	—	0.770	0.17
[68]	19.92	0.640	—
[69]	29.20	0.964	—
[70]	21.56	0.745	—

成了视觉效果更优的无雾图像。为验证该方法的有效性,作者分别在 I-HAZE 和 O-HAZE 数据集上进行了实验,实验结果如图 5(b2)所示。结果表明,与单纯基于 CycleGAN 的去雾方法相比,该方法在定量指标和定性视觉效果上均取得了显著改进。在 NTIRE 2018 单幅图像去雾挑战赛的 O-HAZE 数据集上,平均 PSNR 和 SSIM 结果分别达到 19.92 和 0.64,具体如表 3 所示。Wang 等^[69]提出了一种 Cycle-SNSPGAN 模型,该模型通过引入带有补丁模块的高效 SN-Soft-Patch GAN 网络框架,如图 5(c)所示,并结合下式中的循环自感知损失函数,显著提升了模型对真实世界模糊图像的泛化能力。

$$L_{\text{self-per}} = \left\| \Psi[G_A(\mathbf{x})] - \Psi(\mathbf{x}) \right\|_1 + \left\| \Psi[G_B(\mathbf{y})] - \Psi(\mathbf{y}) \right\|_1 \quad (6)$$

式中: $G_A(\mathbf{x})$ 和 $G_B(\mathbf{y})$ 表示感知相似度; $\Psi(\mathbf{x})$ 表示从

ImageNet 上预训练的 VGG-16 网络第 2 层和第 5 层提取的特征图。此外,作者还将所提方法与其他方法进行了对比实验。结果表明,该方法在视觉效果和定量评估指标上均表现出色,验证了其在复杂场景中的鲁棒性和有效性。为更清晰地展示该方法的性能优势,表 3 列出了具体的评价指标,其中,PSNR 达到 29.20, SSIM 达到 0.964,充分证明了该方法具有卓越的去模糊能力。然而, CycleGAN 的输入包含两种不同分布的数据,这可能导致生成器在学习过程中出现混淆现象。因此, Sun 等^[70]基于 CycleGAN 提出了一种无监督的多分支高频增强网络(UME-Net),如图 5(d)所示。该网络通过引入多分支解码模块,有效解决了基于 CycleGAN 的方法在生成器学习过程中可能出现的混淆问题。同时,通过设计共享编码模块和高频分量增强模块,增强了特征表示的一致性并补偿了网络中丢失的高频信息,从而显著提升了 UME-Net 的重建能力。实验结果表明,该方法在具有挑战性的基准数据集上的表现优于现有的无监督图像去雾方法,展现了其在复杂场景下的强大适应性和鲁棒性。

除了改进 GAN 网络结构外,将物理模型及其他学习方式与 GAN 结合也成为提升模型性能的重要途径。Shi 等^[71]提出了一种融合物理过程的 GAN,该方法能够直接从完全缺乏目标结构信息的散斑图中重建隐藏目标,如图 6(a1)所示。该研究基于不同散射介

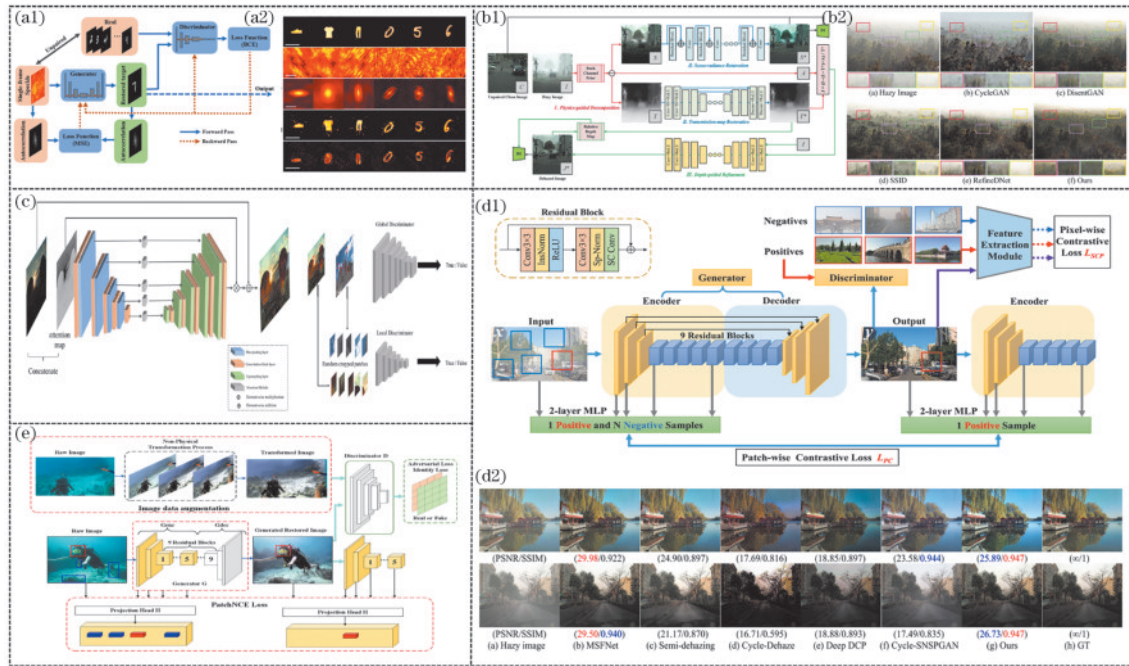


图 6 基于物理模型和其他学习方式的 GAN。(a1)(a2)融合自相关一致性的无先验 GAN 方法的网络结构及网络模型输出的结果^[71]; (b1)(b2) PDR-GAN 的网络结构及其与其他方法的对比结果^[72]; (c) EnlightenGAN 的网络结构^[73]; (d1)(d2) UCL-Dehaze 的流程及其与其他方法的对比结果^[74]; (e) 基于对比度学习的 PatchNCE 网络结构^[75]

Fig. 6 GAN based on physical models and other learning approaches. (a1)(a2) Network structure of the priori-free GAN incorporating autocorrelation consistency and model output results^[71]; (b1)(b2) network structure of PDR-GAN and comparison results with other methods^[72]; (c) network structure of EnlightenGAN^[73]; (d1)(d2) flow of UCL-Dehaze and comparison results with other methods^[74]; (e) PatchNCE network structure based on contrast learning^[75]

质下散斑图自相关与原始图像自相关之间的内在关系,通过双重约束机制(即判别器约束和散斑自相关与原图自相关一致性约束),实现了无监督的在线优化。该方法的优势在于,判别器无需依赖与散斑图对应的原始图像或任何先验信息进行训练,仅需对单帧散斑图进行在线优化即可重构未知散射介质后的隐藏目标,结果如图 6(a2)所示。此外,表 4 展示了该方法在 660 目散射片条件下重建结果的评价指标,其中 PSNR、SSIM 和平均绝对误差(MAE)均达到较高水平,进一步说明了该方法在复杂散射环境中的优越泛化性能。然而,当目标尺寸超出记忆效应范围时,自相关结构会出现退化现象,这可能导致该方法在重构隐藏目标时失效。Chen 等^[72]在 GAN 框架下将物理引导的恢复阶段与深度信息引导的细化阶段相结合,提出了一种端

到端的非成对图像去雾方法(PDR-GAN),如图 6(b1)所示。该方法在恢复阶段通过嵌入暗通道先验为网络提供约束,并生成初步的去雾图像;在细化阶段,通过挖掘深度信息与透射图之间的潜在关系,进一步改进前一阶段的结果并恢复远处的细节信息。对比实验结果如图 6(b2)所示,验证了该方法在真实有雾环境中的有效性。此外,该方法在 HazeCityscape 数据集上的 SSIM 达到 0.947(表 4),进一步证明了结合两种阶段的方式能有效提升无监督模型在去雾任务中的性能。Jiang 等^[73]提出了一种高效的无监督生成对抗网络 EnlightenGAN,如图 6(c)所示。该方法通过下式中的自我特征保留损失和自正则化注意力机制实现无监督训练,并通过引入全局-局部判别器结构处理变化的光照条件。

表 4 基于不同物理模型和其他学习方式的 IUL 方法性能分析

Table 4 Performance analysis of IUL methods based on different physical models and other learning methods

Ref.	PSNR ↑	SSIM ↑	MAE ↓	MSE ↓	NIQE ↓	BRISQUE ↓	SSEQ ↓	PI ↓	UCIQE ↑	UIQM ↑
[71]	17.81	0.664	0.0293	—	—	—	—	—	—	—
[72]	26.30	0.947	—	—	—	—	—	—	—	—
[74]	26.73	0.947	—	—	3.736	24.658	26.028	3.412	—	—
[75]	18.10	0.710	—	1095.2	—	—	—	—	18.10	4.012

$$L_{\text{SFP}}(\mathbf{I}_L) = \frac{1}{W_{i,j}H_{i,j}} \sum_{x=1}^{W_{i,j}} \sum_{y=1}^{H_{i,j}} \left\{ \phi_{i,j}(\mathbf{I}_L) - \phi_{i,j}[G(\mathbf{I}_L)] \right\}^2 \quad (7)$$

式中: \mathbf{I}_L 表示输入的低亮度图像; $G(\mathbf{I}_L)$ 表示生成器的增强输出; $\phi_{i,j}(\cdot)$ 表示从 ImageNet 上预训练的 VGG-16 模型中提取的特征图; i 表示第 i 个最大池化层; j 表示第 i 个最大池化层之后的第 j 个卷积层; $W_{i,j}$ 和 $H_{i,j}$ 是提取的特征图的维度。作者将 EnlightenGAN 与几种最先进的增强方法进行了比较,实验结果表明,该方法在视觉质量、无参考图像质量评估和人类主观调查三个方面均取得了优异成果。此外,与现有的监督训练增强方法相比,EnlightenGAN 能够灵活提升不同真实世界场景下低光图像的视觉效果。多范式融合策略可弥补单一学习的局限性,因此部分研究选择在对抗学习的基础上引入其他学习方式,例如对比学习和迁移学习。Wang 等^[74]提出的 UCL-Dehaze[网络结构如图 6(d1)所示]利用对比学习最大化输入图像与恢复图像之间的互信息,并采用像素级自对比感知损失对其进行训练。

$$L_{\text{SCP}} = \sum_{i=1}^n \omega_i \cdot \frac{\|\phi_i(\mathbf{R}_c) - \phi_i[G(\mathbf{x})]\|_1}{\|\phi_i(\mathbf{R}_h) - \phi_i[G(\mathbf{x})]\|_1} \quad (8)$$

式中: \mathbf{R}_c 表示真实世界的干净图像; \mathbf{R}_h 表示真实世界的灰度图像; $G(\mathbf{x})$ 表示初步修复图; $\phi_i(\cdot)$, $i=1, 2, \dots, n$ 表示从 ImageNet 上预训练的 VGG-16 网络中提取的第 i 个隐藏特征, ω_i 表示权重系数。此外,作者通过多种对比实验证明,该方法在少量训练数据的情况下仍能展现卓越的去雾效果[图 6(d2)]。如表 4

所示,该方法在 SOTS 户外数据集上的评价指标表现优异。其中,PSNR、SSIM、NIQE、BRISQUE、结构相似性评价(SSEQ)和主观感知质量(PI)分别达到 26.73、0.947、3.736、24.658、26.028 和 3.412,充分表明了该方法在真实环境中的优越性及其实际应用潜力。Liang 等^[75]提出将 GAN 中的循环一致性损失替换为基于对比度学习的 PatchNCE 对比度损失,如图 6(e)所示。该方法通过使用对抗损失和强度损失,保证了恢复图像的视觉效果和结构相似性。研究人员分别利用 UIEB 和 U45 两种水下图像数据集对该模型进行了定性和定量实验。其中,PSNR、SSIM、均方误差(MSE)、UCIQE 和 UIQM 指标分别达到 18.10、0.71、1095.20、18.10 和 4.012,证明了其在改善图像视觉质量方面的卓越能力,并在特定场景下进行了应用测试。

本节根据 GAN 方法创新的侧重点不同,将上述 IUL 方法划分为三类:基于不同 GAN 变体的方法^[62-65]、基于 CycleGAN 的改进方法^[67-70]以及基于与物理模型和其他学习方式相结合的方法^[71-75]。其中,基于不同 GAN 变体的方法倾向于在传统 GAN 的生成器和判别器架构中引入全新网络模块,以提升模型的特征分析能力,从而改善散射介质中的成像质量。然而,由于网络架构的固有限制,这些方法难以完全适应复杂散射环境下的图像去噪和增强任务。基于 CycleGAN 的改进方法以 CycleGAN 为基础,通过独特的双生成器-双判别器架构与循环一致性约束实现由散斑图像向目标图像的跨域转换,显著扩展了模型在复杂散射环境中的适用性。但这类方法在训练过程

中易受输入数据分布差异的影响,可能导致生成器出现混淆现象。相比之下,基于与物理模型和其他学习方式相结合的方法通过融合物理先验或引入其他学习方式来提升网络模型的成像性能,这在一定程度上增加了模型的可解释性或降低了对大量训练数据的依赖。然而,物理模型的先验假设或组合学习方式之间可能存在的不兼容性,也会限制模型的泛化能力。

GAN作为一种广泛应用于无监督学习的神经网络模型,在散射介质成像领域发挥着至关重要的作用。凭借生成器与判别器的对抗训练机制,GAN能够有效提升模型在图像生成中的真实性和对图像细节的还原能力,从而解决IDL在复杂散射环境中面临的标签数据获取困难和泛化能力不足等问题。此外,研究者还通过引入高效网络模块、优化无标签参考的损失函数、采用改进的GAN模型以及整合物理模型与先进学习方法,显著提升了IUL的成像质量和泛化能力。然而,基于GAN的无监督成像模型仍存在训练过程不稳定、计算资源需求高及可解释性不足等局限性。这些问题亟待解决,同时也成为未来该领域发展的重要研究方向。

2.3 基于扩散模型的无监督散射介质成像

随着人工智能技术的快速发展,数学理论与深度学习理论的深度融合推动了无监督生成式模型领域的显著进步。基于先进的数学框架,研究者提出了一系列创新性生成模型,包括基于分数的生成模型^[76]、噪声条件评分网络^[77]以及去噪扩散概率模型^[78]等,其中,扩散模型凭借其在图像生成任务中的卓越表现,已成为当前生成模型领域的研究热点之一。去噪扩散概率模型(DDPM)^[78]的提出不仅推动了扩散模型在图像生成领域的广泛应用,还为其在散射介质成像等复杂场景中的应用提供了新的理论框架和技术支持。

DDPM是一种基于马尔可夫链的生成模型,其核心思想是通过扩散过程与逆向重构过程实现图像生成。如图7所示,扩散过程(从右至左)是一个逐步加噪的过程:从原始图像出发,经过 T 次迭代加噪,最终将图像转化为各向同性的标准高斯分布。重构过程(从左至右)则是一个逆向的去噪过程:从标准高斯分布出发,通过逐步降噪,最终重建出与原始图像相同的清晰图像。这种双向过程构成了DDPM的完整生成框架,为图像生成任务提供了理论基础和可扩展的建模方法。基于DDPM,Sivaanpu等^[79]通过一个简单的U-Net架构来增强超声图像质量,如图8(a1)所示。该方法通过对初始无噪声图像及其相应的噪声图像进行

插值生成中间图像,在每个扩散步骤中对图像进行迭代降噪,同时保留图像的纹理信息,从而提高图像重建的视觉效果。具体成像效果如图8(a2)所示,该方法相较于对比模型能生成更清晰、无噪声的图像。此外,表5展示了该方法在CAMUS数据集上的PSNR、SSIM和MSE结果,相较于文中引用的其他算法,其指标均达到最优值。Xu等^[80]提出一种基于双条件的DDPM,如图8(b)所示。该方法在退化信息估计和重建目标信息两部分均引入了DDPM。在退化信息估计过程中,针对低分辨率图像,通过研究退化信息分布与潜在特征分布之间的可逆映射,构建了一种基于DDPM的退化信息预测器;在重建过程中,将预测的退化分布信息和低分辨率图像作为条件信息,构建了一个学习低分辨率图像到高分辨率图像之间映射的基于DDPM的重建器。DDPM通过其独特的前向扩散过程和反向重构过程,显式地建模了数据的潜在分布。这种双向机制不仅能够精确捕捉数据的潜在结构,还能进一步增强数据的关键特征表示,使得DDPM在特征学习和数据增强方面展现出显著优势,为下游任务提供了更鲁棒的特征支持。表5展示了该方法在两个随机特征值分别为1.2、2.4以及 0° 随机旋转角的情况下,在来源于GoogleEarth的数据集上取得的PSNR、LPIPS(Learned Perceptual Image Patch Similarity)和FID(Frechet Inception Distance)值,均优于KernelGAN、DIP-FKP和SRDiff方法。Li等^[81]基于DDPM实现了红外强度与偏振特征的高效融合,并在此过程中引入多方向偏振图像作为引导条件,增强模型对红外偏振信息的解析能力,如图8(c1)所示。该方法利用DDPM的生成能力,在扩散过程中逐步融合红外强度信息和多方向偏振特征,不仅能够高效地融合多模态特征,还显著提高了后续任务的准确性与计算效率,结果如图8(c2)所示。虽然该方法未采用表5中较为常见的指标,但给出了用于评价后续识别任务的一系列指标,且与对比的众多方法相比,所有指标均取得最优值。Palanirajan等^[82]建立了一个结合DDPM与大气散射模型的混合模型,如图8(d1)所示,利用DDPM在图像生成方面的强大能力,通过逆向去噪过程有效恢复因雾霾而退化的图像细节,具体实验结果如图8(d2)所示。表5给出了该方法取得的PSNR、SSIM以及LPIPS值,这些指标均表现出色。此外,该方法在多个图像去雾基准数据集上均达到了SOTA性能,显著提升了图像质量。得益于去雾效果的提升,该方法还进一步提




图7 DDPM的具体流程^[78]

Fig. 7 Concrete process of DDPM^[78]

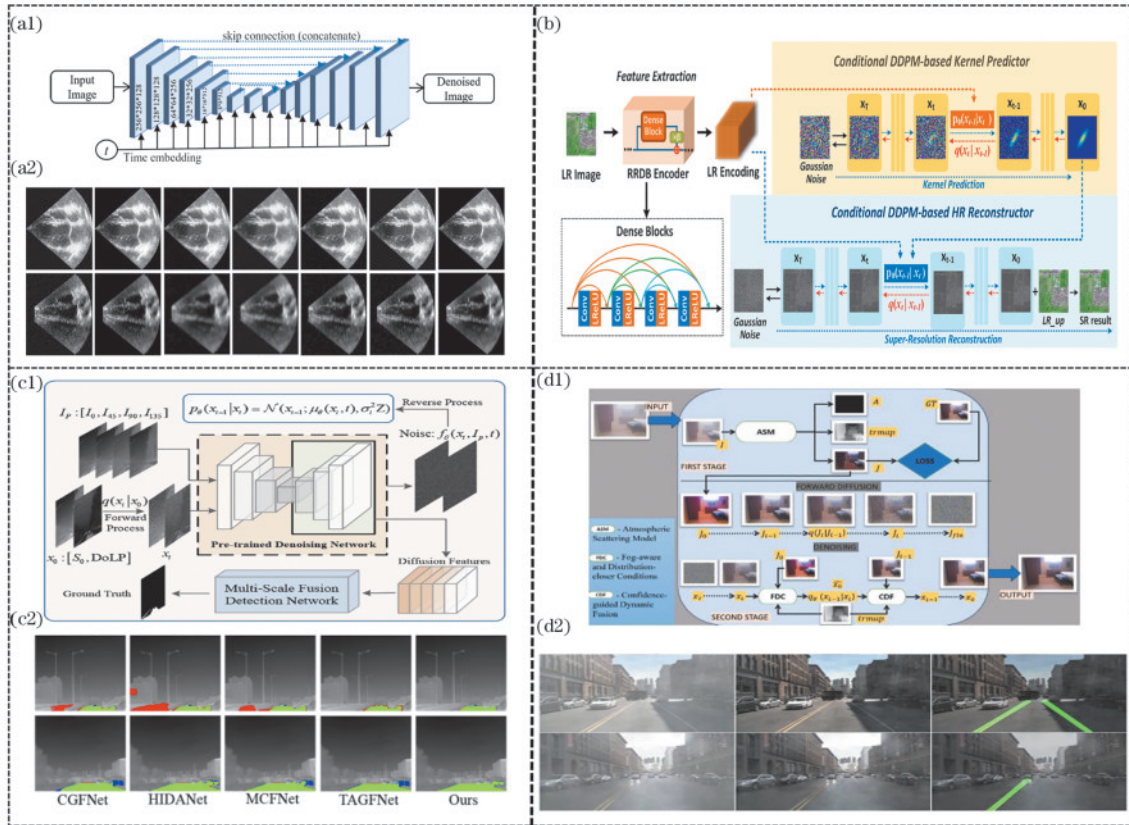


图8 基于DDPM的IUL方法。(a1)(a2)增强网络模型及其输出结果^[79]；(b)基于双条件的DDPM^[80]；(c1)(c2)基于DDPM的融合方法以及不同道路检测方法的对比结果^[81]；(d1)(d2)基于DDPM和大气散射模型的混合模型及其去雾、检测结果^[82]

Fig. 8 DDPM-based IUL methods. (a1)(a2) Enhanced network model and its output results^[79]；(b) new biconditional-based DDPM^[80]；(c1)(c2) DDPM-based fusion method and comparison results of different road inspection methods^[81]；(d1)(d2) hybrid model based on DDPM and atmospheric scattering model and results of the model dehazing and detection^[82]

表5 基于不同扩散模型的IUL方法性能分析

Table 5 Performance analysis of IUL method based on different diffusion models

Ref.	PSNR ↑	SSIM ↑	MSE ↓	LPIPS ↓	FID ↓
[79]	31.0923	0.8914	14.5778	—	—
[80]	24.2600	—	—	0.1760	80.99
[82]	38.5900	0.0989	—	0.0040	—

高了车道识别的准确性与鲁棒性,为自动驾驶等实际应用场景提供了可靠的技术支持。

相比于GAN,扩散模型的训练过程更加稳定且具有较好的灵活性。得益于其对特征的引导与增强作用,该技术不仅能够单独作为去噪模型使用,还能为复杂散射环境下的特征分析与提取提供有效的处理手段。尽管扩散模型在图像生成领域取得了显著进展,但其在散射介质成像中的应用尚未得到深入探索。因此,未来的研究可以将散射理论与扩散模型有机结合,通过理论创新与算法优化,进一步提升IUL的性能。这不仅能够提高IUL的成像质量,还可以拓展其在复杂散射环境下的应用范围,为散射介质成像领域带来新的发展机遇。

基于生成模型的无监督散射介质成像已成为该领

域的主要研究方向之一。研究人员以GAN为基础,通过优化网络结构、设计新型损失函数以及引入物理先验知识等多种策略,显著提升了基于GAN的IUL的成像效果与泛化能力。此外,随着生成模型技术的发展,新兴的扩散模型在散射介质成像任务中也展现出优异性能,为IUL领域提供了新的研究思路和技术支持。如果结合多种生成模型的优势及更精细的物理建模,有望进一步提升IUL的成像效果与应用范围。

3 基于CNN的无监督散射介质成像

在数据驱动散射介质成像领域,CNN凭借其高效的特征分析与提取能力,成为主流的网络框架^[25,83]。无监督学习由于缺乏标签数据的约束,对数据表征及提取能力提出了更高要求。因此,在卷积神经网络的基础上,研究人员通过针对不同任务设计特定模块与损失函数,以实现无监督散射介质成像。具体而言,Yang等^[84]分别设计了交互融合模块和迭代优化模块来实现无监督的去雾算法,如图9(a1)所示,并通过设计4个无参考的视觉驱动损失函数对模型进行优化。该方法在人工合成数据集和真实数据集上均获得了较好的成像效果,如图9(a2)所示,且相应的评价指标可与一些监督学习方法相匹配。此外,该方法还在多个

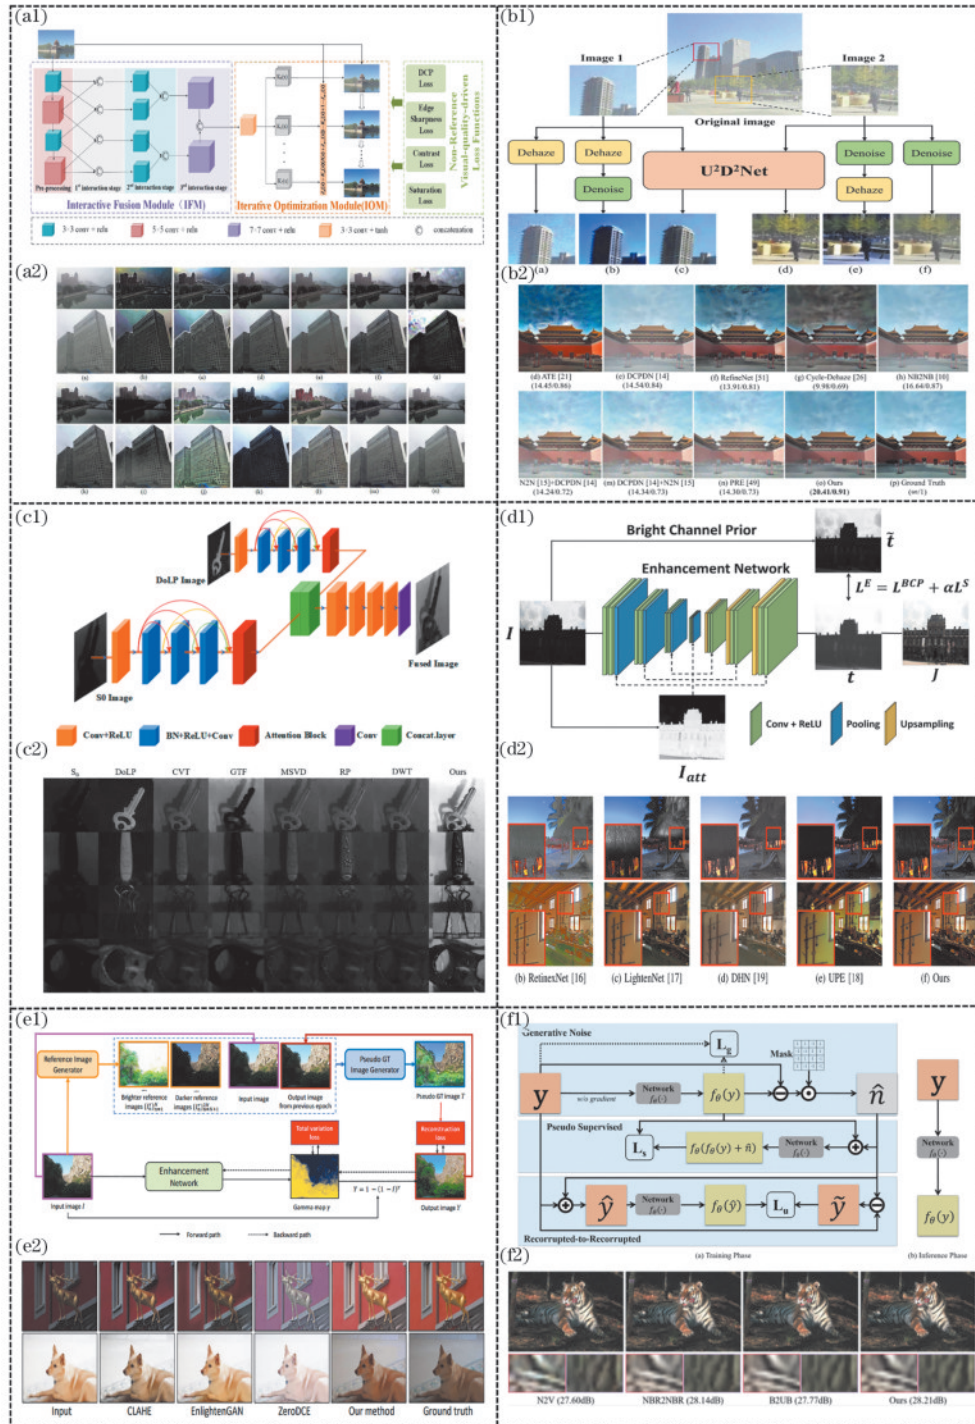


图9 基于CNN的IUL方法。(a1)(a2)基于交互融合模块和迭代优化模块的去雾算法网络结构及其与不同方法的对比结果^[84]；(b1)(b2)相似度融合策略算法流程及其与不同方法的对比结果^[85]；(c1)(c2)无监督融合方法的网络结构及其与不同方法的对比结果^[86]；(d1)(d2)通过亮通道生成伪标签方法的网络结构及其与不同方法的对比结果^[87]；(e1)(e2)通过多源图像合成伪真实图像的具体算法流程及其与不同方法的对比结果^[89]；(f1)(f2)通过估计噪声模型推断真实数据分布的具体算法流程及其与其他方法的对比结果^[90]

Fig. 9 CNN-based IUL methods. (a1)(a2) Network structure of dehazing algorithm based on interactive fusion module and iterative optimization module^[84]; (b1)(b2) algorithm process of similarity fusion strategy and its comparison results with different methods^[85]; (c1)(c2) network structure of unsupervised fusion method and its comparison results with different methods^[86]; (d1)(d2) network structure of generating pseudo labels through bright channels and its comparison results with different methods^[87]; (e1)(e2) specific algorithm process of synthesizing pseudo real images through multi-source images and its comparison results with different methods^[89]; (f1)(f2) specific algorithm process for inferring the distribution of real data through estimating noise models and its comparison results with other methods^[90]

数据集上进行了定量测试, PSNR、SSIM 和 UQI (Universal Quality Index) 分别达到 20.51、0.80 和 0.865, 如表 6 所示, 充分表明了该方法对多种数据集的适用性。Ding 等^[85]将传输特征图嵌入到每一层网络中, 如图 9(b1) 所示, 以恢复图片中的目标信息。此外, 还提出了相似度融合策略, 充分利用前阶段输出之间的相关性与互补性。该方法与其他现有方法在模拟数据集和真实数据集上分别进行了大量对比实验, 如图 9(b2) 所示的实验结果表明, 该方法具有更优的去雾能力与泛化性能。作者还对该方法在不同数据集上的实验结果进行了定量分析, 其在 RESIDE-T 数据集上的评价指标表现最优, PSNR 和 SSIM 分别达到 23.5837 和 0.9266, 如表 6 所示。在另外两个数据集 HSTS 和 BeDDE 上, 该方法也取得了较好的结果, 其中 SSIM 分别达到 0.8214 和 0.9197。这些数据充分表明所提出的策略在提升去雾模型质量方面具有显著作用。Cheng 等^[86]通过设计基于多尺度结构相似度的无参考标签图像的融合损失函数, 将光强图像与偏振图像进行融合, 如图 9(c1) 所示, 从而提高目标图像的细节表征能力。融合后的水下图像更加细节化, 与单纯的光照强度图像相比, 该方法的信息熵和标准差分别提高了 24.48% 和 139%。此外, 在信息熵(IE)、SD、MI 指标上也分别达到 7.1073、40.46、1.6808。该方法不仅显著提高了成像效果[图 9(c2)], 还因其较快的处理速度, 展现出满足水下视频实时处理需求的潜力。除了设计无参考图像的损失函数外, 一些方法还通过采用在目标域上生成置信度高的伪标注来实现无监督的训练过程。例如, Lee 等^[87]使用亮通道先验^[88]生成的伪真值定义损失函数, 如图 9(d1) 所示, 然后使用该损失函数训练由编码器和解码器组成的增强网络。如图 9(d2) 中与其他方法的对比实验结果表明, 该方法在无需真实标注数据的情况下能够有效提升图像质量, 同时避免了监督学习中标签数据获取困难的问题, 其 NIQE 和 LOE (Lightness Order Error) 指标分别达到 3.30 和 305。Nguyen 等^[89]主要通过利用多源图像合成伪真实图像来模拟所有潜在的曝光场景, 进而训练增强网络, 如图 9(e1) 所示。该方法具体通过一个新颖的、能够反映人类对图像视觉良好评价的指标 $Y = 1 - (1 - I)^\gamma$, 驱动伪真实图像的生成过程, 其中 γ 是一个随机数, I 为原始图片。该方法在 SICE 和 Afifi 数据集上进行了广泛实验, 如图 9(e2) 所示的实验结果表明, 该方法

表 6 基于不同 CNN 算法的 IUL 方法性能分析

Table 6 Performance analysis of IUL method based on different CNN algorithms

Ref.	PSNR↑	SSIM↑	UQI↑	IE↓	SD↑	MI↑	NIQE↑	LOE↓
[84]	20.51	0.800	0.865	-	-	-	-	-
[85]	23.58	0.926	-	-	-	-	-	-
[86]	-	0.518	-	7.107	40.46	1.680	-	-
[87]	-	-	-	-	-	-	3.30	305
[89]	19.72	0.875	-	-	-	-	-	-
[90]	30.19	0.839	-	-	-	-	-	-

较以前的无监督方法具有很大优势, 并获得了与有监督方法相当的结果。此外, 该方法在 SICE 和 Afifi 上的定量分析结果 PSNR 和 SSIM 分别达到 19.72 和 0.875、17.74 和 0.704, 表明采用新的指标生成伪标签能够促进模型更好地适应不同的环境。Liu 等^[90]提出了一种创新的无监督去噪方法, 该方法通过估计噪声模型间接推断真实数据分布, 如图 9(f1) 所示, 从而实现无需标签数据的去噪模型训练。如图 9(f2) 所示, 实验结果表明, 该方法在多种噪声类型与强度下均表现出优异的去噪性能, 尤其在缺乏先验噪声信息的场景中展现了显著的鲁棒性与泛化能力。如表 6 所示, 该方法在没有噪声先验的情况下的定量分析能够达到较高水平, 其中 PSNR 和 SSIM 分别达到 30.19 和 0.839, 充分表明了该方法的高效去噪能力。

CNN 凭借其强大的特征提取能力, 能够与多种成像技术及数据处理方法灵活结合, 从而构建更为强大的成像系统^[91-93]。然而, 由于无监督学习场景下缺乏标签数据的约束, 其应用范围受到一定限制。基于 CNN 的方法在简单散射环境中能够实现良好的成像效果, 但在处理复杂散射环境时, 其成像质量与环境适应性均出现下降。因此, 探索更有效的约束条件以优化无监督模型的训练过程, 从而进一步提升无监督散射介质成像模型在复杂环境下的鲁棒性与适应性。这也将成为无监督学习在散射成像领域应用的重要研究方向之一。

为了明确上述 4 种 IUL 方法的核心差异, 现选取每类方法中一项具有代表性的工作进行对比分析, 不同方法的性能分析如表 7 所示。基于自编码器的 UDNet 方法^[53]通过概率不确定性建模与编码器-解码器架构, 有效解决了水下图像随机失真和低对比度问题, 并在无参考指标 UIQM 和 UCIQE 上表现出色。

表 7 不同 IUL 典型方法的性能分析

Table 7 Performance analysis of different typical IUL methods

Ref.	PSNR↑	SSIM↑	UIQM↑	UCIQE↑	EN↓	SD↑	MI↑	MSE↓	UQI↑
[53]	22.9600	0.7710	3.265	0.749	-	-	-	-	-
[65]	71.1607	0.7669	-	-	4.1478	52.464	3.0764	-	-
[79]	31.0923	0.8914	-	-	-	-	-	14.5778	-
[84]	20.5100	0.8000	-	-	-	-	-	-	0.865

然而,该方法受限于潜在空间的表征能力,导致其对图像的增强效果有限。基于注意力引导的双鉴别器 GAN 方法^[65]通过注意力机制和双判别器设计融合光强与偏振信息,多维度信息的有效融合实现了对弱目标的高效视觉增强,其 PSNR 值达到 71.1607,显著优于其他对比方法。但 GAN 的训练过程依赖生成器与判别器的对抗博弈,存在计算资源消耗大和模型稳定性不足的问题。基于 U-Net 架构的 DDPM 方法^[79]通过插值技术和简单的 U-Net 结构实现了超声图像的高质量重建,在 PSNR 和 SSIM 指标上均表现突出。但其迭代式生成过程导致推理速度较慢,难以满足对实时性要求较高的图像恢复任务。基于交互融合模块和迭代优化模块的 CNN 方法^[84]通过设计 4 个无参考的视觉驱动损失函数,在合成和真实数据集上达到了接近监督学习的性能水平。然而,模型性能的限制使其在复杂散射环境下的泛化能力不足。总体而言,基于自编码器和 CNN 的方法在计算效率和资源消耗方面更具优势,而基于 GAN 和扩散模型的方法在图像生成质量上表现更优。

4 结束语

本文围绕散射介质成像,以无监督学习理论为核心框架,深入研究了散射介质成像技术。以优化无监督散射介质成像的各类网络框架为线索,详细分析了不同网络框架在散射介质成像任务中的模型训练理论、优点及局限性。此外,针对不同模型的设计方案和成像效果进行了详细描述与分析。基于无监督学习训练策略的散射介质成像摆脱了对精确配对数据约束的依赖,展现出对多种散射环境更强的适应性和泛化性。同时,为了更好地分析和提取深层次的图像特征以提升 IUL 性能,研究人员通过引入先进的网络模块、优化无标签参考的损失函数等手段,增强了模型对数据的分析和提取能力。并且,研究人员还结合不同物理模型和多种学习方式,提升了无监督训练过程中的特征调控能力,从而提高无监督模型的成像质量和对变化散射环境的适应性。

尽管当前的 IUL 方法通过摆脱对高质量标签数据的依赖,降低了复杂散射环境下的数据获取难度,但也限制了模型对有效信息的提取能力和特征分析的准确性。例如,部分基于 AE 的方法由于潜在空间表征能力有限,生成的增强图像容易出现细节模糊的现象。基于 DDPM 的方法虽然在图像生成质量上占优,但复杂的迭代降噪过程需要大量计算资源,无法满足实时性需求。此外,相较于监督学习,无监督学习为提升性能通常会引入较为复杂的模块(如混合注意力模块等),这导致模型参数量大幅增加和计算效率下降,限制了其在真实环境中的应用。因此,针对以上问题,IUL 领域的未来研究方向可从网络架构优化及约束条件设计两个维度推进。一方面,通过探索更高效、更具

适应性的网络结构,提升模型的特征提取和表达能力。例如,设计 Transformer 与 CNN 的混合架构,可在降低计算复杂度的同时增强模型的远程建模能力。另一方面,需设计更为精确的约束条件(如基于物理模型的先验约束、多尺度特征一致性约束或任务驱动的自适应约束等),以引导模型从无序的散射数据中挖掘更具鲁棒性的特征表示。其中:基于物理模型的先验约束通过融合散射介质的物理特性(如光传输衰减等),可为模型训练提供更具解释性的引导;多尺度特征一致性约束针对散射退化的复杂特性,通过多尺度特征处理增强模型的鲁棒性;任务驱动的自适应约束则聚焦实际任务需求,灵活调整模型的优化方向。此外,随着人工智能技术的快速发展,新兴生成模型与散射介质成像算法的深度融合显著推动了 IUL 领域的进步。尽管目前新兴生成模型(如扩散模型、基于分数的生成模型等)在散射介质成像中的应用场景相对有限,但其在生成质量、特征建模和噪声鲁棒性等方面的优势已初步显现。随着理论研究的不断深入和应用场景的进一步拓展,新兴生成模型与跨学科结合有望成为无监督散射介质成像领域的重要方法,为解决复杂散射环境下的图像恢复问题提供更强大的技术支持。

参 考 文 献

- [1] Han J F, Yang K C, Xia M, et al. Resolution enhancement in active underwater polarization imaging with modulation transfer function analysis[J]. Applied Optics, 2015, 54(11): 3294-3302.
- [2] Huang B J, Liu T G, Hu H F, et al. Underwater image recovery considering polarization effects of objects[J]. Optics Express, 2016, 24(9): 9826-9838.
- [3] Xu Q, Guo Z Y, Tao Q Q, et al. Multi-spectral characteristics of polarization retrieve in various atmospheric conditions[J]. Optics Communications, 2015, 339: 167-170.
- [4] Hu T W, Shen F, Wang K P, et al. Broad-band transmission characteristics of polarizations in foggy environments[J]. Atmosphere, 2019, 10(6): 342.
- [5] Horstmeyer R, Ruan H W, Yang C. Guidestar-assisted wavefront-shaping methods for focusing light into biological tissue[J]. Nature Photonics, 2015, 9(9): 563-571.
- [6] Li D K, Xu C X, Zhang M, et al. Measuring glucose concentration in a solution based on the indices of polarimetric purity[J]. Biomedical Optics Express, 2021, 12(4): 2447-2459.
- [7] Shen F, Zhang M, Guo K, et al. The depolarization performances of scattering systems based on the Indices of Polarimetric Purity (IPPs)[J]. Optics Express, 2019, 27(20): 28337-28349.
- [8] Ntziachristos V. Going deeper than microscopy: the optical imaging frontier in biology[J]. Nature Methods, 2010, 7(8): 603-614.
- [9] 戴琼海, 索津莉, 季向阳, 等. 计算影像学: 全光视觉信

- 息的计算采集[M]. 北京: 清华大学出版社, 2016.
- Dai Q H, Suo J L, Ji X Y, et al. Computational photography: computational capture of plenoptic visual information[M]. Beijing: Tsinghua University Press, 2016.
- [10] 丁佳渝, 彭斯颖. 光热显微成像: 一种免标记、高分辨的成像技术[J]. 激光与光电子学进展, 2023, 60(22): 2200001.
- Ding J Y, Peng S Y. Photothermal microimaging: a non-invasive and high-resolution imaging technique[J]. Laser & Optoelectronics Progress, 2023, 60(22): 2200001.
- [11] 章镇宇, 石岩, 戴晟昕, 等. 非视域成像技术研究进展[J]. 激光与光电子学进展, 2023, 60(14): 1400001.
- Zhang Z Y, Shi Y, Dai S X, et al. Research progresses on non-line-of-sight imaging technology[J]. Laser & Optoelectronics Progress, 2023, 60(14): 1400001.
- [12] 金欣, 王泉宇, 杜东宇, 等. 散射成像研究现状及展望[J]. 激光与光电子学进展, 2021, 58(18): 1811002.
- Jin X, Wang X Y, Du D Y, et al. Progress and prospect of scattering imaging[J]. Laser & Optoelectronics Progress, 2021, 58(18): 1811002.
- [13] Osnabrugge G, Horstmeyer R, Papadopoulos I N, et al. Generalized optical memory effect[J]. Optica, 2017, 4(8): 886-892.
- [14] Haskel M, Stern A. Modeling optical memory effects with phase screens[J]. Optics Express, 2018, 26(22): 29231-29243.
- [15] Yoon J, Lee K, Park J, et al. Measuring optical transmission matrices by wavefront shaping[J]. Optics Express, 2015, 23(8): 10158-10167.
- [16] Drémeau A, Liutkus A, Martina D, et al. Reference-less measurement of the transmission matrix of a highly scattering material using a DMD and phase retrieval techniques[J]. Optics Express, 2015, 23(9): 11898-11911.
- [17] Paudel H P, Stockbridge C, Mertz J, et al. Focusing polychromatic light through strongly scattering media[J]. Optics Express, 2013, 21(14): 17299-17308.
- [18] Osnabrugge G, Amitonova L V, Vellekoop I M. Blind focusing through strongly scattering media using wavefront shaping with nonlinear feedback[J]. Optics Express, 2019, 27(8): 11673-11688.
- [19] Li D K, Xu C X, Yan L S, et al. High-performance scanning-mode polarization based computational ghost imaging (SPCGI) [J]. Optics Express, 2022, 30(11): 17909-17921.
- [20] Ferri F, Magatti D, Lugiato L A, et al. Differential ghost imaging[J]. Physical Review Letters, 2010, 104(25): 253603.
- [21] Xu G Q, Zhang X Z, Wang W, et al. Dynamic manipulation of mid-infrared polarized thermal emission enabled by In_3SbTe_2 metasurfaces[J]. Advanced Photonics Nexus, 2025, 4(1): 016008.
- [22] Li D K, Montes I, Canabal-Carbia M, et al. Enhanced characterization of depolarizing samples using indices of polarization purity and polarizance-reflection-transformation spaces[J]. Advanced Photonics Nexus, 2025, 4(1): 016009.
- [23] Ding H J, Ding M L, Lv T Y, et al. Polarimetric observable based optical remote sensing systems for heterogeneous layered scattering environments[J]. Optics and Lasers in Engineering, 2025, 189: 108916.
- [24] Li S, Deng M, Lee J, et al. Imaging through glass diffusers using densely connected convolutional networks[J]. Optica, 2018, 5(7): 803-813.
- [25] Li Y Z, Xue Y J, Tian L. Deep speckle correlation: a deep learning approach toward scalable imaging through scattering media[J]. Optica, 2018, 5(10): 1181-1190.
- [26] 林冰, 樊学强, 李德奎, 等. 基于深度学习的散射光场成像研究进展[J]. 量子电子学报, 2022, 39(6): 880-898.
- Lin B, Fan X Q, Li D K, et al. Research progress of imaging through scattering media based on deep learning[J]. Chinese Journal of Quantum Electronics, 2022, 39(6): 880-898.
- [27] Zhu S, Guo E L, Gu J, et al. Efficient color imaging through unknown opaque scattering layers via physics-aware learning[J]. Optics Express, 2021, 29(24): 40024-40037.
- [28] Lyu M, Wang H, Li G W, et al. Learning-based lensless imaging through optically thick scattering media[J]. Advanced Photonics, 2019, 1(3): 036002.
- [29] Yang M, Liu Z H, Cheng Z D, et al. Deep hybrid scattering image learning[J]. Journal of Physics D: Applied Physics, 2019, 52(11): 115105.
- [30] Li D K, Lin B, Wang X Y, et al. High-performance polarization remote sensing with the modified U-Net based deep-learning network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5621110.
- [31] Lin B, Fan X Q, Guo Z Y. Self-attention module in a multi-scale improved U-Net (SAM-MIU-Net) motivating high-performance polarization scattering imaging[J]. Optics Express, 2023, 31(2): 3046-3058.
- [32] Ma Q, Jiang J J, Liu X M, et al. Deep unfolding network for spatio-spectral image super-resolution[J]. IEEE Transactions on Computational Imaging, 2021, 8: 28-40.
- [33] Liu Z C, Roy M, Prasad D K, et al. Physics-guided loss functions improve deep learning performance in inverse scattering[J]. IEEE Transactions on Computational Imaging, 2022, 8: 236-245.
- [34] Lin B, Chen W Y, Fan X Q, et al. Transformer-based improved U-Net for high-performance underwater polarization imaging[J]. Optics & Laser Technology, 2025, 181: 111664.
- [35] Fan X Q, Lin B, Guo Z Y. Infrared polarization-empowered full-time road detection via lightweight multi-pathway collaborative 2D/3D convolutional networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(9): 12762-12775.
- [36] Fan X Q, Ding M L, Lv T Y, et al. Meta-DNET-UPI: efficient underwater polarization imaging combining deformable convolutional networks and meta-learning[J]. Optics & Laser Technology, 2025, 187: 112900.
- [37] Luan X, Wang Q, Fan H J, et al. Feature distillation and guide network for unsupervised underwater image enhancement[J]. Engineering Applications of Artificial

- Intelligence, 2024, 136: 109006.
- [38] Zhu P L, Liu Y C, Wen Y Q, et al. [Unsupervised underwater image enhancement via content-style representation disentanglement](#)[J]. Engineering Applications of Artificial Intelligence, 2023, 126: 106866.
- [39] Xiao L Z, Wang S B, Zhang J, et al. [Poisson2Poisson-Sparse: unsupervised poisson noise image denoising based on sparse modeling](#)[J]. Signal Processing, 2025, 230: 109870.
- [40] Ni Z K, Yang W H, Wang S Q, et al. [Towards unsupervised deep image enhancement with generative adversarial network](#)[J]. IEEE Transactions on Image Processing, 2020, 29: 9140-9151.
- [41] Jiang Q P, Mao Y D, Cong R M, et al. [Unsupervised decomposition and correction network for low-light image enhancement](#)[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 19440-19455.
- [42] Zhou W H, Zhu D M, Shi M, et al. [Deep images enhancement for turbid underwater images based on unsupervised learning](#)[J]. Computers and Electronics in Agriculture, 2022, 202: 107372.
- [43] Hu J J, Guo X Y, Chen J F, et al. [A two-stage unsupervised approach for low light image enhancement](#) [J]. IEEE Robotics and Automation Letters, 2021, 6(4): 8363-8370.
- [44] Lin F, Zhang H Q, Wang J, et al. [Unsupervised image enhancement under non-uniform illumination based on paired CNNs](#)[J]. Neural Networks, 2024, 170: 202-214.
- [45] Fu Y, Hong Y, Chen L W, et al. [LE-GAN: unsupervised low-light image enhancement network using attention module and identity invariant loss](#)[J]. Knowledge-Based Systems, 2022, 240: 108010.
- [46] Li J, Zhang C Y, Zhu W, et al. [A comprehensive survey of image generation models based on deep learning](#)[J]. Annals of Data Science, 2025, 12(1): 141-170.
- [47] Cao H Q, Tan C, Gao Z Y, et al. [A survey on generative diffusion models](#)[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 2814-2830.
- [48] Chen H, Xiang Q, Hu J X, et al. [Comprehensive exploration of diffusion models in image generation: a survey](#)[J]. Artificial Intelligence Review, 2025, 58(4): 99.
- [49] de Souza V L T, Marques B A D, Batagelo H C, et al. [A review on generative adversarial networks for image generation](#)[J]. Computers & Graphics, 2023, 114: 13-25.
- [50] Ohno H. [Auto-encoder-based generative models for data augmentation on regression problems](#)[J]. Soft Computing, 2020, 24(11): 7999-8009.
- [51] Sonawane J, Patil M, Birajdar G. [A novel feature extraction and mapping using convolutional autoencoder for enhancement of Underwater image/video](#)[J]. ITM Web of Conferences, 2022, 44: 03066.
- [52] Yu Y, Qin C F. [An end-to-end underwater-image-enhancement framework based on fractional integral retinex and unsupervised autoencoder](#)[J]. Fractal and Fractional, 2023, 7(1): 70.
- [53] Saleh A, Sheaves M, Jerry D, et al. [Adaptive deep learning framework for robust unsupervised underwater image enhancement](#)[J]. Expert Systems with Applications, 2025, 268: 126314.
- [54] Thai D H, Fei X Q, Le M T, et al. [Riesz-quincunx-UNet variational autoencoder for unsupervised satellite image denoising](#)[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 5404519.
- [55] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems, December 8-13, 2014, Montreal, Quebec, Canada. New York: ACM Press, 2014: 2672-2680.
- [56] Li J, Skinner K A, Eustice R M, et al. [WaterGAN: unsupervised generative network to enable real-time color correction of monocular underwater images](#)[J]. IEEE Robotics and Automation Letters, 2018, 3(1): 387-394.
- [57] She C Y, Chen T, Duan S K, et al. [SAGAN: deep semantic-aware generative adversarial network for unsupervised image enhancement](#)[J]. Knowledge-Based Systems, 2023, 281: 111053.
- [58] Yin J K, Wang Y, Guan B W, et al. [Unsupervised underwater image enhancement based on disentangled representations via double-order contrastive loss](#)[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 4201815.
- [59] Shi Y M, Wang B Q, Wu X P, et al. [Unsupervised low-light image enhancement by extracting structural similarity and color consistency](#)[J]. IEEE Signal Processing Letters, 2022, 29: 997-1001.
- [60] Li J F, Li Y P, Zhuo L, et al. [USID-net: unsupervised single image dehazing network via disentangled representations](#)[J]. IEEE Transactions on Multimedia, 2022, 25: 3587-3601.
- [61] Liu J L, Wang S L, Chen C, et al. [DFP-Net: an unsupervised dual-branch frequency-domain processing framework for single image dehazing](#)[J]. Engineering Applications of Artificial Intelligence, 2024, 136: 109012.
- [62] Yang S L, Qu B W, Liu G S, et al. [Unsupervised learning polarimetric underwater image recovery under nonuniform optical fields](#)[J]. Applied Optics, 2021, 60(26): 8198-8205.
- [63] Yu W S, Zhao L Q, Zhong T. [Unsupervised low-light image enhancement based on generative adversarial network](#)[J]. Entropy, 2023, 25(6): 932.
- [64] Wang R J, Jiang B, Yang C, et al. [MAGAN: unsupervised low-light image enhancement guided by mixed-attention](#)[J]. Big Data Mining and Analytics, 2022, 5(2): 110-119.
- [65] Zhou H P, Zeng X B, Lin B, et al. [Polarization motivating high-performance weak targets' imaging based on a dual-discriminator GAN](#)[J]. Optics Express, 2024, 32(3): 3835-2851.
- [66] Zhu J Y, Park T, Isola P, et al. [Unpaired image-to-image translation using cycle-consistent adversarial networks](#)[C]//2017 IEEE International Conference on Computer Vision (ICCV), October 22-29, 2017, Venice, Italy. New York: IEEE Press, 2017: 2242-2251.

- [67] Yamazaki K, Horisaki R, Tanida J. Imaging through scattering media based on semi-supervised learning[J]. Applied Optics, 2020, 59(31): 9850-9854.
- [68] Engin D, Genc A, Ekenel H K. Cycle-dehaze: enhanced CycleGAN for single image dehazing[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), June 18-22, 2018, Salt Lake City, UT, USA. New York: IEEE Press, 2018: 938-9388.
- [69] Wang Y Z, Yan X F, Guan D H, et al. Cycle-SNSPGAN: towards real-world image dehazing via cycle spectral normalized soft likelihood estimation patch GAN [J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(11): 20368-20382.
- [70] Sun H, Luo Z M, Ren D, et al. Unsupervised multi-branch network with high-frequency enhancement for image dehazing[J]. Pattern Recognition, 2024, 156: 110763.
- [71] Shi Y J, Guo E L, Bai L F, et al. Prior-free imaging unknown target through unknown scattering medium[J]. Optics Express, 2022, 30(10): 17635-17651.
- [72] Chen X, Li Y F, Kong C H, et al. Unpaired image dehazing with physical-guided restoration and depth-guided refinement[J]. IEEE Signal Processing Letters, 2022, 29: 587-591.
- [73] Jiang Y F, Gong X Y, Liu D, et al. EnlightenGAN: deep light enhancement without paired supervision[J]. IEEE Transactions on Image Processing, 2021, 30: 2340-2349.
- [74] Wang Y Z, Yan X F, Wang F, et al. UCL-dehaze: toward real-world image dehazing via unsupervised contrastive learning[J]. IEEE Transactions on Image Processing, 2024, 33: 1361-1374.
- [75] Liang D, Chu J L, Cui Y G, et al. NPT-UL: an underwater image enhancement framework based on nonphysical transformation and unsupervised learning[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 5608819.
- [76] Song Y, Ermon S. Improved techniques for training score-based generative models[EB/OL]. (2020-06-17) [2024-12-12]. <https://arxiv.org/abs/2006.09011v2>.
- [77] Song Y, Ermon S. Generative modeling by estimating gradients of the data distribution[EB/OL]. (2020-07-12) [2024-12-12]. <https://arxiv.org/abs/1907.05600>.
- [78] Ho J, Jain A N, Abbeel P. Denoising diffusion probabilistic models[EB/OL]. (2020-06-17)[2024-12-12]. <https://arxiv.org/abs/2006.11239>
- [79] Sivaanpu A, Noga M, Becher H, et al. Denoising echocardiography with an improved diffusion model[C]//2024 46th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), July 15-19, 2024, Orlando, FL, USA. New York: IEEE Press, 2024: 1-4.
- [80] Xu M Z, Ma J, Zhu Y Y. Dual-diffusion: dual conditional denoising diffusion probabilistic models for blind super-resolution reconstruction in RSIs[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 6008505.
- [81] Li K Y, Qi M B, Liu Y M, et al. Fusing infrared polarization images for road detection via denoising diffusion probabilistic models[J]. Optics Letters, 2024, 49(18): 5312-5315.
- [82] Palanirajan S, Natarajan B, Baalaji A, et al. Revamped lane detection in hazy environments using denoising diffusion probabilistic model[C]//2024 International Conference on Modeling, Simulation & Intelligent Computing (MoSICom), December 9-11, 2024, Dubai, United Arab Emirates. New York: IEEE Press, 2024: 546-551.
- [83] Li H, Wu X J, Kittler J. Infrared and visible image fusion using a deep learning framework[C]//2018 24th International Conference on Pattern Recognition (ICPR), August 20-24, 2018, Beijing, China. New York: IEEE Press, 2018: 2705-2710.
- [84] Yang A P, Liu Y M, Wang J B, et al. Visual-quality-driven unsupervised image dehazing[J]. Neural Networks, 2023, 167: 1-9.
- [85] Ding B S, Zhang R H, Xu L X, et al. U2D2Net: unsupervised unified image dehazing and denoising network for single hazy image enhancement[J]. IEEE Transactions on Multimedia, 2023, 26: 202-217.
- [86] Cheng H Y, Zhang D Q, Zhu J C, et al. Underwater target detection utilizing polarization image fusion algorithm based on unsupervised learning and attention mechanism [J]. Sensors, 2023, 23(12): 5594.
- [87] Lee H S, Sohn K, Min D B. Unsupervised low-light image enhancement using bright channel prior[J]. IEEE Signal Processing Letters, 2020, 27: 251-255.
- [88] Wang Y T, Zhuo S J, Tao D P, et al. Automatic local exposure correction using bright channel prior for under-exposed images[J]. Signal Processing, 2013, 93(11): 3227-3238.
- [89] Nguyen H, Tran D, Nguyen K, et al. PSENet: progressive self-enhancement network for unsupervised extreme-light image enhancement[C]//2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV), January 2-7, 2023, Waikoloa, HI, USA. New York: IEEE Press, 2023: 1756-1765.
- [90] Liu Y K, Wan B W, Shi D M, et al. Generative recorruped-to-recorruped: an unsupervised image denoising network for arbitrary noise distribution[J]. Remote Sensing, 2023, 15(2): 364.
- [91] Chang X Y, Zhao R F, Jiang S W, et al. Complex-domain-enhancing neural network for large-scale coherent imaging [J]. Advanced Photonics Nexus, 2023, 2(4): 046006.
- [92] Yang J G, Choi S, Kim J, et al. Recent advances in deep-learning-enhanced photoacoustic imaging[J]. Advanced Photonics Nexus, 2023, 2(5): 054001.
- [93] Wang J Y, Fan J C, Zhou B, et al. Hybrid reconstruction of the physical model with the deep learning that improves structured illumination microscopy [J]. Advanced Photonics Nexus, 2023, 2(1): 016012.